

Predicción de salarios en carreras de Ciencia de Datos: un enfoque de regresión supervisada sobre el dataset *Data Science Careers and Salaries 2025*

1st Geraldine Acevedo Restrepo
Curso Modelos y Simulación II
Universidad de Antioquia
Medellín, Colombia
geraldine.acevedo@udea.edu.co

2nd Juan Manuel Areiza Ospina
Curso Modelos y Simulación II
Universidad de Antioquia
Medellín, Colombia
jmanuel.areiza@udea.edu.co

3rd Vanesa Herrera Marulanda
Curso Modelos y Simulación II
Universidad de Antioquia
Medellín, Colombia
vanesa.herrera1@udea.edu.co

Resumen—Este trabajo propone un enfoque de aprendizaje supervisado para la predicción de salarios en carreras relacionadas con Ciencia de Datos, a partir del dataset *Data Science Careers and Salaries 2025*. El problema se aborda como una tarea de regresión, donde el salario ofrecido se estima mediante variables asociadas al cargo, nivel de experiencia, ubicación, modalidad de trabajo, características de la empresa y habilidades requeridas. La metodología contempla limpieza de datos, tratamiento de valores faltantes, transformación de variables categóricas y comparación de modelos lineales y no lineales. El desempeño de los modelos se evaluará mediante métricas de error y ajuste, con el fin de identificar las variables más relevantes en la estimación salarial y construir una solución reproducible para el análisis del mercado laboral en Ciencia de Datos.

Index Terms—Predicción salarial, Ciencia de Datos, aprendizaje supervisado, regresión, aprendizaje de máquina.

I. INTRODUCCIÓN

El mercado laboral de la Ciencia de Datos, la Inteligencia Artificial y el Aprendizaje de Máquina ha experimentado un crecimiento sostenido durante la última década. La demanda de perfiles como *Data Scientist*, *Data Engineer*, *Machine Learning Engineer* y *Data Analyst* coexiste con diferencias importantes en niveles de experiencia, ubicación geográfica, modalidad de trabajo, tamaño de la empresa, sector económico y habilidades requeridas. En este contexto, la estimación salarial se convierte en una tarea relevante tanto para las empresas, que necesitan definir compensaciones competitivas y sostenibles, como para los profesionales, que requieren referentes confiables para negociar su remuneración.

Este proyecto aborda la predicción de salarios en carreras relacionadas con Ciencia de Datos a partir del dataset *Data Science Careers and Salaries 2025*, publicado en Kaggle. El conjunto de datos contiene 944 registros de ofertas laborales publicadas durante 2025 y está compuesto por variables asociadas al cargo, nivel de experiencia, modalidad de trabajo, empresa, ubicación, sector económico, tamaño de la organización, ingresos, salario ofrecido y habilidades técnicas requeridas. Cada registro representa una oferta laboral individual, lo que permite analizar la relación entre las características de una vacante y la compensación económica ofrecida.

El problema se plantea como una tarea de aprendizaje supervisado de regresión, debido a que la variable objetivo corresponde al salario y tiene naturaleza numérica continua. Para desarrollar el modelo predictivo, se aplicarán estrategias de limpieza de datos, tratamiento de valores faltantes, transformación de variables categóricas y preparación de variables textuales o numéricas que requieran procesamiento previo. De forma general, se contempla el uso de técnicas de codificación para variables nominales, ordinales y de alta cardinalidad, así como la normalización de variables numéricas cuando el modelo lo requiera.

La estrategia de modelado considera la construcción de un modelo base lineal y la comparación con modelos no lineales de mayor capacidad predictiva. En particular, se evaluarán modelos como *Ridge Regression*, Random Forest, Gradient Boosting y XGBoost, utilizando una estrategia de validación cruzada con cinco particiones. El desempeño se analizará mediante métricas de regresión como RMSE, MAE, R^2 y MAPE, con el propósito de comparar la calidad de las predicciones y determinar qué enfoque ofrece mejores resultados para el conjunto de datos seleccionado.

Con este trabajo se busca construir una solución reproducible que permita estimar salarios en el sector de Ciencia de Datos y, al mismo tiempo, identificar las variables que tienen mayor influencia en dicha estimación. La propuesta puede servir como apoyo para el análisis del mercado laboral, la toma de decisiones en recursos humanos y la comprensión de factores asociados a la compensación en perfiles tecnológicos.

II. ESTADO DEL ARTE

La predicción salarial mediante aprendizaje de máquina ha sido abordada en distintos contextos laborales, especialmente en áreas relacionadas con tecnologías de la información, mercados profesionales y perfiles de alta especialización. En general, los trabajos revisados coinciden en formular el problema como una tarea de regresión supervisada, debido a que el salario corresponde a una variable numérica continua. Además, emplean métricas como RMSE, MAE, MAPE y R^2 para evaluar el desempeño de los modelos predictivos.

Matboui y Alghamdi [1] desarrollaron modelos de regresión para estimar salarios a partir de características ocupacionales y organizacionales del mercado laboral saudí. Su principal aporte fue comparar modelos estadísticos tradicionales con métodos no paramétricos, incluyendo regresión lineal múltiple, procesos gaussianos bayesianos y redes neuronales artificiales. Las métricas utilizadas fueron RMSE y R^2 . Los autores reportaron que el modelo basado en procesos gaussianos bayesianos redujo el RMSE hasta en un 80 % frente a la regresión lineal múltiple, lo que evidencia la utilidad de modelos más flexibles para capturar relaciones complejas entre las variables laborales y el salario.

Wang [2] propuso un enfoque de aprendizaje de máquina para predecir el salario inicial de egresados universitarios, incorporando variables asociadas a experiencia, ubicación y características de la empresa. El trabajo se diferencia por combinar modelos de regresión con análisis de importancia de variables, permitiendo identificar los factores con mayor influencia en la predicción. Se evaluaron modelos como regresión lineal múltiple, Random Forest y XGBoost mediante validación cruzada de cinco particiones. Las métricas usadas fueron R^2 ajustado, MAE y MAPE. Los resultados indicaron que la experiencia, el tamaño de la empresa y la ubicación concentraron el 87 % de la importancia predictiva, y que XGBoost obtuvo el menor MAPE.

Jiang [3] estudió la predicción de tendencias salariales en la industria de Ciencia de Datos a partir de registros laborales recientes del sector. Este trabajo es especialmente relevante para el presente proyecto porque aborda un dominio similar y compara modelos aplicados a salarios de perfiles tecnológicos. El autor evaluó Random Forest, XGBoost, redes neuronales artificiales y Support Vector Regression. Las métricas empleadas fueron RMSE y R^2 . Los resultados mostraron que las redes neuronales y Support Vector Regression obtuvieron los menores errores, mientras que XGBoost presentó mejor eficiencia computacional. Además, se identificó que la experiencia y la ubicación geográfica fueron variables determinantes en la estimación salarial.

Martín *et al.* [4] abordaron la predicción salarial en el mercado laboral de tecnologías de la información con un conjunto de datos caracterizado por pocas muestras y alta dimensionalidad. Su aporte principal consistió en comparar modelos adecuados para escenarios donde el número de variables puede ser elevado frente al número de registros, situación comparable con el dataset utilizado en este proyecto. Los autores evaluaron modelos regularizados como Lasso, Ridge y Elastic-Net, además de Support Vector Regression y Random Forest. Las métricas usadas fueron RMSE, MAE y correlación de Pearson. Los resultados señalaron que Lasso y Support Vector Regression ofrecieron un buen equilibrio entre interpretabilidad y desempeño predictivo, y que la experiencia y el tipo de contrato fueron factores relevantes para explicar el salario.

En conjunto, los trabajos revisados muestran que la regresión supervisada es el enfoque predominante para la predicción salarial, especialmente cuando se dispone de variables labora-

les, organizacionales y geográficas. También se observa que modelos como Random Forest, XGBoost, redes neuronales y Support Vector Regression suelen superar a los modelos lineales tradicionales cuando existen relaciones no lineales entre las características y el salario. Finalmente, las investigaciones coinciden en que el nivel de experiencia, la ubicación, el tipo de cargo y algunas características de la empresa son variables relevantes para explicar la compensación, lo cual respalda la selección de variables y modelos propuesta en este trabajo.

III. METODOLOGÍA

III-A. Descripción y preparación de los datos

El conjunto de datos está compuesto por 944 registros y 13 columnas, sin duplicados exactos. La variable objetivo, el salario, se obtuvo a partir de la columna original en formato textual, de la que se derivaron los valores mínimo, máximo y promedio; este último se seleccionó como objetivo y sus valores atípicos se trataron mediante el rango intercuartílico (IQR). Los valores faltantes, concentrados en la modalidad de trabajo, el nivel de experiencia y el tipo de propiedad, se imputaron asignando una categoría explícita de valor desconocido a las variables categóricas y la mediana a las numéricas, y se añadieron indicadores de dato faltante.

La codificación empleó representación One-Hot para las variables nominales de baja y media cardinalidad, codificación ordinal para el nivel de experiencia, conversión a valor numérico para el tamaño de la empresa y los ingresos, transformación de la fecha de publicación en días transcurridos y, para las habilidades, variables binarias de las más frecuentes junto con su conteo. Las variables de alta cardinalidad, como la empresa, la ubicación y la sede, se agruparon por frecuencia y por similitud semántica. La matriz resultante quedó con 164 variables predictoras.

III-B. Análisis exploratorio

El análisis de correlación entre las variables numéricas (Fig. 1) muestra que el salario mínimo y el máximo están casi perfectamente correlacionados con el promedio, por lo que se excluyeron como predictores para evitar fuga de información. El resto de variables numéricas presentan correlaciones débiles con el salario, lo que anticipa que la capacidad predictiva recae principalmente en las variables categóricas.

III-C. Configuración experimental

Los datos se dividieron en un 80 % para entrenamiento y un 20 % para prueba, manteniendo este último aislado durante toda la experimentación. La comparación de modelos se realizó con validación cruzada de cinco particiones sobre el conjunto de entrenamiento; para cada métrica se reporta la media y la desviación estándar entre particiones como estimación de su intervalo de confianza. En el modelo final se empleó además una partición estratificada por rangos salariales, con el fin de conservar distribuciones de salario similares entre conjuntos. Se evaluaron versiones con y sin transformación logarítmica de la variable objetivo y se conservó la versión sin transformar por su mejor desempeño. Se tomó el RMSE como métrica




Figura 1. Matriz de correlación entre las variables numéricas. Los ejes corresponden a las variables y el color indica el coeficiente de correlación de Pearson.

principal de comparación, por penalizar con mayor fuerza los errores grandes, relevantes en un contexto salarial; las métricas MAE, R^2 y MAPE se reportan como complemento.

IV. ENTRENAMIENTO Y EVALUACIÓN DE LOS MODELOS

IV-A. Modelos comparados e hiperparámetros

Se compararon ocho modelos de cinco familias: un modelo paramétrico de regresión (Ridge), uno no paramétrico de k vecinos más cercanos (KNN), cuatro ensambles de árboles (Random Forest, Gradient Boosting, XGBoost y CatBoost), una red neuronal de tipo perceptrón multicapa (MLP) y una máquina de vectores de soporte con kernel de función de base radial (SVR-RBF); se añadió un predictor trivial como línea base. La Tabla I resume la malla de hiperparámetros analizada.

Tabla I
HIPERPARÁMETROS ANALIZADOS Y MALLA DE VALORES

Modelo	Malla de valores
Ridge	$\alpha \in \{0, 1, 1, 5, 10, 25, 50, 100, 250, 500, 1000\}$
KNN	$n_neighbors \in \{3, 5, 7, 9, 15\}$; $weights \in \{uniform, distance\}$
Random Forest	$n_estimators = 300$; $max_depth \in \{None, 10, 20\}$; $min_samples_leaf = 2$
Gradient Boosting	$n_estimators \in \{180, \dots, 420\}$; $learning_rate \in \{0.025, \dots, 0.075\}$; $max_depth \in \{2, 3, 4\}$; $subsample \in \{0.75, \dots, 1.0\}$
XGBoost	$n_estimators = 300$; $learning_rate = 0.05$; $max_depth = 3$; $subsample = 0.9$
SVR-RBF	$C \in \{0.1, 1, 5, 10\}$; $\epsilon \in \{0.1, 1, 5\}$; $\gamma \in \{scale, auto\}$
MLP	$hidden_layer_sizes \in \{(64,), (128, 64), (128, 64, 32)\}$; $\alpha \in \{10^{-4}, 10^{-3}\}$
CatBoost	$iterations \in \{300, \dots, 900\}$; $learning_rate \in \{0.025, \dots, 0.07\}$; $depth \in \{4, 5, 6\}$

IV-B. Resultados en validación cruzada

La Tabla II y la Fig. 2 resumen los resultados de la validación cruzada. Los ensambles de árboles obtuvieron el menor

error, con Random Forest y Gradient Boosting prácticamente empatados. KNN alcanzó un desempeño cercano al de Ridge, la red neuronal quedó por detrás y la máquina de vectores de soporte no logró superar la línea base. Este comportamiento es coherente con la elevada dimensionalidad dispersa generada por la codificación One-Hot, escenario en el que estos dos últimos modelos son muy sensibles a la escala y requieren un ajuste de hiperparámetros más exhaustivo.

Tabla II
VALIDACIÓN CRUZADA DE CINCO PARTICIONES (MEDIA Y DESVIACIÓN ESTÁNDAR)

Modelo	RMSE	MAE	R^2
Random Forest	43,706 $\pm$ 2922	32,600	0,556 $\pm$ 0,043
Gradient Boosting	43,809 $\pm$ 2540	33,228	0,554 $\pm$ 0,028
XGBoost	44,259 $\pm$ 2660	33,865	0,545 $\pm$ 0,037
Ridge	46,029 $\pm$ 4069	34,994	0,508 $\pm$ 0,060
KNN	46,344 $\pm$ 2663	33,428	0,501 $\pm$ 0,030
MLP	51,668 $\pm$ 2969	37,573	0,378 $\pm$ 0,069
Línea base	65,665 $\pm$ 2195	54,596	-0,001 $\pm$ 0,001
SVR-RBF	66,397 $\pm$ 2011	54,259	-0,024 $\pm$ 0,015




Figura 2. RMSE promedio en validación cruzada de cinco particiones. Las barras de error corresponden a la desviación estándar entre particiones. Eje vertical: RMSE en dólares; eje horizontal: modelo.

IV-C. Resultados en el conjunto de prueba

La Tabla III y la Fig. 3 presentan el desempeño sobre el conjunto de prueba. CatBoost obtuvo el mejor resultado, con un RMSE de 31 856 dólares y un R^2 de 0.743, superando con claridad a los demás modelos.

Tabla III
DESEMPEÑO EN EL CONJUNTO DE PRUEBA

Modelo	RMSE	MAE	R^2	MAPE
CatBoost	31,856	23,871	0,743	28,2 %
Gradient Boosting	42,915	33,245	0,484	43,0 %
Random Forest	43,061	32,133	0,480	44,5 %
XGBoost	43,168	32,944	0,478	42,6 %
KNN	44,696	32,684	0,440	41,6 %
Ridge	46,496	35,580	0,394	44,0 %
MLP	52,201	39,248	0,236	46,3 %
SVR-RBF	59,700	47,859	0,001	88,5 %
Línea base	60,332	48,860	-0,021	82,8 %




Figura 3. Comparación del RMSE en el conjunto de prueba. Eje vertical: RMSE en dólares; eje horizontal: modelo.

IV-D. Ajuste de hiperparámetros y modelo final

Se aplicó una búsqueda aleatoria de hiperparámetros con validación cruzada sobre Gradient Boosting. El modelo ajustado redujo el RMSE de prueba de 42 915 a 41 701 y elevó el R^2 de 0.484 a 0.512, pero amplió la diferencia entre entrenamiento y prueba, lo que evidencia mayor sobreajuste (Tabla IV). Posteriormente se evaluó CatBoost, que maneja las variables categóricas de forma nativa sin expandir la dimensionalidad mediante One-Hot. Su versión base alcanzó un RMSE de 31 856 dólares y un R^2 de 0.743 en prueba, con una diferencia moderada respecto al entrenamiento. El ajuste fino de CatBoost mejoró levemente algunas métricas pero aumentó esa diferencia, por lo que se conservó la versión base como modelo definitivo.

Tabla IV
COMPARACIÓN DE ENTRENAMIENTO Y PRUEBA

Modelo	RMSE entr.	RMSE prueba	R^2 entr.	R^2 prueba
Gradient Boosting original	34,215	42,915	0,729	0,484
Gradient Boosting ajustado	20,274	41,701	0,905	0,512
CatBoost base	27,320	31,856	0,824	0,743

V. REDUCCIÓN DE DIMENSIÓN

V-A. Análisis individual de variables

La importancia de variables del mejor modelo basado en árboles (Fig. 4), junto con el análisis de correlación previo, indica que la capacidad predictiva se concentra en pocas variables: la modalidad de trabajo, la ubicación, el tamaño de la empresa, el nivel de experiencia y los ingresos. En contraste, los días desde la publicación presentan correlación casi nula e importancia baja, y la mayoría de las columnas One-Hot de alta cardinalidad tienen importancia cercana a cero. Estas últimas, junto con los días desde la publicación, son las principales candidatas a eliminación, lo que sugiere que existe redundancia explotable mediante reducción de dimensión. Las técnicas siguientes se aplicaron sobre la matriz procesada y se reevaluaron los dos mejores modelos de esa representación, Random Forest y Gradient Boosting; CatBoost se analiza aparte porque maneja las variables categóricas de forma nativa.




Figura 4. Doce variables más importantes según Gradient Boosting. Eje horizontal: importancia relativa; eje vertical: variable.

V-B. Extracción de características lineal

Se aplicó análisis de componentes principales (PCA) ajustado únicamente con el conjunto de entrenamiento, transformando luego el de prueba para evitar fuga de información. El criterio elegido fue conservar el 95 % de la varianza, lo que requirió 38 componentes frente a las 164 variables originales, una reducción del 76.8 %, como se aprecia en la Fig. 5. Al reevaluar los dos mejores modelos, el desempeño empeoró frente a las variables originales (Tabla V): el R^2 de Random Forest descendió de 0.480 a 0.318, lo que indica que la proyección lineal destruye parte de la estructura categórica relevante.




Figura 5. Varianza explicada acumulada por PCA. Eje horizontal: número de componentes; eje vertical: varianza acumulada.

Tabla V
RESULTADOS CON PCA (38 COMPONENTES, REDUCCIÓN DEL 76.8 %)

Modelo	RMSE prueba	R^2 prueba	R^2 entr.	MAPE
Random Forest	49,312	0,318	0,906	53,5 %
Gradient Boosting	50,914	0,273	0,844	55,7 %
Ridge	56,550	0,103	0,375	66,1 %

V-C. Extracción de características no lineal

Se aplicó la técnica Uniform Manifold Approximation and Projection (UMAP), ajustada solo con el conjunto de entrenamiento, probando distintos números de componentes y reevaluando Ridge, KNN, Random Forest y Gradient Boosting. La mejor configuración fue Random Forest con 15 componentes, una reducción del 90.9 %, pero el desempeño fue muy inferior, con un RMSE de 57 339 dólares y un R^2 de 0.078 en prueba (Tabla VI). UMAP preserva la estructura local útil para la visualización, pero la proyección de baja dimensión no conserva la información necesaria para la regresión salarial.

Tabla VI
MEJOR RESULTADO CON UMAP (15 COMPONENTES, REDUCCIÓN DEL 90.9 %)

Modelo	RMSE prueba	MAE prueba	R^2 prueba	MAPE
Random Forest	57,339	43,727	0,078	69,5 %

VI. DISCUSIÓN Y CONCLUSIONES

La predicción salarial en Ciencia de Datos resultó un problema complejo por la presencia de variables categóricas de alta cardinalidad, información textual, valores faltantes y ruido en los salarios. Entre los modelos comparados, los ensambles de árboles superaron a la regresión, a KNN, a la red neuronal y a la máquina de vectores de soporte, y CatBoost se seleccionó como modelo definitivo por alcanzar el menor error y la menor diferencia entre entrenamiento y prueba. Su ventaja proviene del manejo nativo de variables categóricas, que evita la expansión de dimensionalidad de la codificación One-Hot y el sobreajuste asociado. Las técnicas de reducción de dimensión no mejoraron el desempeño, ya que tanto la proyección lineal como la no lineal degradaron las métricas, lo que confirma que la información categórica del conjunto de datos es esencial y difícilmente comprimible sin pérdida.

Estos resultados coinciden con la literatura. Como en Jiang [3] y Wang [2], la experiencia, la ubicación y las características de la empresa fueron determinantes, y los modelos no lineales superaron a los lineales. A diferencia de Matbouli y Alghamdi [1], cuya mejora provino de modelos bayesianos, en este trabajo el mayor avance se logró con un modelo especializado en datos categóricos. El desempeño obtenido es competitivo dado el tamaño reducido del conjunto de datos y su heterogeneidad, en línea con las dificultades reportadas por Martín *et al.* [4] en escenarios de pocas muestras y alta dimensionalidad. Como trabajo futuro se recomienda enriquecer el conjunto de datos con variables como país, moneda, años de experiencia, tipo de contrato, nivel educativo y beneficios, así como explorar codificación basada en el objetivo y modelos híbridos, con el fin de reducir el error y aumentar la capacidad explicativa.

REFERENCIAS

[1] Y. T. Matbouli and S. M. Alghamdi, "Statistical Machine Learning Regression Models for Salary Prediction Featuring Economy-Wide Activities and Occupations," *Information*, vol. 13, no. 10, Art. no. 495, 2022, doi: 10.3390/info13100495.

[2] Y. Wang, "Prediction of Factors Influencing the Starting Salary of College Graduates Based on Machine Learning," *Wireless Communications and Mobile Computing*, vol. 2022, Art. no. 7845545, pp. 1–11, 2022, doi: 10.1155/2022/7845545.

[3] W. Jiang, "The Investigation and Prediction for Salary Trends in the Data Science Industry," *Applied and Computational Engineering*, vol. 50, pp. 8–14, 2024, doi: 10.54254/2755-2721/50/20241102.

[4] I. Martín, A. Mariello, R. Battiti, and J. A. Hernández, "Salary Prediction in the IT Job Market with Few High-Dimensional Samples: A Spanish Case Study," *International Journal of Computational Intelligence Systems*, vol. 11, no. 1, pp. 1192–1209, 2018, doi: 10.2991/ijcis.11.1.90.