

Predicción de salarios en carreras de Ciencia de Datos: un enfoque de regresión supervisada sobre el dataset *Data Science Careers and Salaries 2025*

Geraldine Acevedo Restrepo, Juan Manuel Areiza Ospina y Vanesa Herrera Marulanda
Curso Modelos y Simulación II
Universidad de Antioquia — 2026

I. DESCRIPCIÓN DEL PROBLEMA

I-A. Contexto y motivación

El mercado laboral de la Ciencia de Datos, la Inteligencia Artificial y el Aprendizaje de Máquina ha experimentado un crecimiento sostenido durante la última década. La fuerte demanda de perfiles como *Data Scientist*, *Data Engineer*, *Machine Learning Engineer* y *Data Analyst* coexiste con una oferta heterogénea en términos de niveles de experiencia, tipo de contratación, ubicación geográfica, tamaño de la empresa y modalidad de trabajo. En este escenario, la fijación de salarios se ha convertido en una tarea compleja tanto para las empresas —que deben ofrecer compensaciones competitivas pero sostenibles— como para los profesionales —que requieren referentes confiables para negociar su remuneración.

Una solución basada en Aprendizaje de Máquina (ML) es particularmente útil en este contexto porque permite: (i) modelar relaciones no lineales y de alto orden entre múltiples variables categóricas y numéricas que influyen en el salario; (ii) generar estimaciones personalizadas de compensación a partir del perfil de un trabajador o una vacante; y (iii) apoyar decisiones estratégicas en recursos humanos, análisis de brechas salariales y estudios de mercado laboral. La disponibilidad pública de registros anonimizados de ofertas laborales del sector de Ciencia de Datos, publicados en plataformas de empleo durante 2025, habilita la construcción de modelos reproducibles y comparables con trabajos previos en la literatura.

I-B. Descripción de la base de datos

El proyecto se desarrolla sobre el dataset *Data Science Careers and Salaries 2025* publicado en Kaggle por la autora Aleesha Nadeem¹. El dataset consolida información de ofertas de empleo del sector de Ciencia de Datos publicadas en 2025 en plataformas de reclutamiento.

La base de datos está compuesta por un archivo CSV con 944 registros de ofertas de empleo en diferentes empresas. El conjunto incluye 13 columnas con detalles del puesto, información de la empresa y habilidades requeridas, donde cada fila corresponde a una oferta laboral individual. La Tabla I resume las **trece variables** que componen el dataset, su tipo y significado.

I-C. Datos faltantes

El análisis exploratorio inicial revela que el dataset presenta valores faltantes en seis de sus trece variables. La variable con mayor proporción de ausencias es *status* (modalidad de trabajo), con 256 registros nulos que representan el 27,1 % del total, seguida de *seniority_level* con 60 nulos (6,4 %) y *ownership* con 47 nulos (5,0 %). Las variables *revenue*, *job_title* y *location* presentan proporciones menores al 2 %. Para el tratamiento de estos valores se contemplan dos estrategias según la proporción de faltantes: (i) imputación por la moda de la variable cuando la proporción sea inferior al 5 %, aplicable a *ownership*, *revenue*, *job_title* y *location*; y (ii) creación de una categoría explícita “*Unknown*” para *status* y *seniority_level*, cuyas proporciones superan dicho umbral, con el fin de no distorsionar las distribuciones originales ni introducir sesgo por imputación en variables con alta tasa de ausencia.

I-D. Codificación de variables

Dado que el algoritmo final será un regresor supervisado, las variables categóricas se transformarán a representaciones numéricas mediante las siguientes técnicas:

- **One-Hot Encoding** para variables nominales de baja cardinalidad: *status* (3 categorías: *on-site*, *hybrid*, *remote*), *industry* (8 sectores) y *ownership* (2 categorías: *Public*, *Private*).
- **Codificación ordinal** para *seniority_level*, con la jerarquía *junior* < *midlevel* < *senior* < *lead*. La variable *job_title*, de solo cuatro valores únicos, se tratará mediante One-Hot Encoding dada su baja cardinalidad.
- **Target Encoding** o **Frequency Encoding** para variables de alta cardinalidad: *company* (420 valores únicos), *location* (431) y *headquarter* (197), con el fin de evitar una explosión dimensional. Este proceso se realizará dentro del *pipeline* de validación cruzada para prevenir fuga de información.
- **Extracción de características** para variables que requieren procesamiento previo: (i) *salary*, variable objetivo, se transformará extrayendo el punto medio cuando se exprese como rango (p.ej. €100,472 – €200,938 → 150705), eliminando el símbolo monetario y convirtiendo a tipo numérico; (ii) *skills* se binarizará mediante *multi-label binarization* o se resumirá con el conteo de

¹<https://www.kaggle.com/datasets/nalisha/data-science-careers-and-salaries-2025>

Tabla I
DESCRIPCIÓN DE LAS VARIABLES DEL DATASET *Data Science Careers and Salaries 2025*.

Variable	Tipo	Descripción
job_title	Catégorica nominal	Título del puesto de trabajo. Toma cuatro valores: <i>data scientist</i> , <i>machine learning engineer</i> , <i>data analyst</i> y <i>data engineer</i> . Presenta 3 valores nulos.
seniority_level	Catégorica ordinal	Nivel de experiencia del trabajador: <i>junior</i> , <i>midlevel</i> , <i>senior</i> y <i>lead</i> . Presenta 60 valores nulos.
status	Catégorica nominal	Modalidad de trabajo: <i>on-site</i> (presencial), <i>hybrid</i> (híbrido) o <i>remote</i> (remoto). Presenta 256 valores nulos.
company	Catégorica de alta cardinalidad	Nombre de la empresa anonimizado (p.ej. <i>company_003</i>). Toma 420 valores únicos sin valores nulos.
location	Catégorica de alta cardinalidad	Ubicación de la oferta; puede incluir múltiples ciudades o regiones en un mismo registro. Presenta 2 valores nulos.
post_date	Catégorica ordinal	Tiempo transcurrido desde la publicación, expresado en texto relativo (p.ej. <i>8 days ago</i> , <i>a month ago</i>).
headquarter	Catégorica nominal	Ciudad y país de la sede principal de la empresa (p.ej. <i>San Jose, CA, US</i>). Toma 197 valores únicos.
industry	Catégorica nominal	Sector económico de la empresa. Toma 8 valores: Retail, Manufacturing, Technology, Finance, entre otros.
ownership	Catégorica nominal	Tipo de propiedad de la empresa: <i>Public</i> (pública) o <i>Private</i> (privada). Presenta 47 valores nulos.
company_size	Texto/Numérica	Número de empleados de la empresa. Requiere limpieza: algunos registros contienen valores monetarios por un aparente intercambio con la columna <i>revenue</i> .
revenue	Texto/Numérica	Ingresos anuales de la empresa (p.ej. €51.10B). Requiere limpieza: algunos registros contienen la cadena "Public".
salary	Variable objetivo. Texto/Numérica continua	Salario ofrecido en euros como valor fijo o rango (p.ej. €100,472 – €200,938). Requiere extracción del punto medio del rango para el modelado.
skills	Texto/Catégorica multivaluada	Lista de habilidades técnicas requeridas, almacenada como cadena con formato de lista Python (p.ej. [<i>'python'</i> , <i>'sql'</i> , <i>'machine learning'</i>]).

habilidades por registro; (iii) *post_date* se convertirá a número de días para capturar la antigüedad de la oferta; y (iv) *company_size* y *revenue* requerirán limpieza por el intercambio de valores detectado entre ambas columnas antes de su transformación numérica.

Las variables numéricas resultantes se estandarizarán con *StandardScaler* cuando se utilicen modelos sensibles a la escala (regresión lineal regularizada, SVR), mientras que los modelos basados en árboles (Random Forest, Gradient Boosting, XGBoost) no requieren este paso. Dado que *salary* es la variable objetivo, será excluida del conjunto de entrada en todos los modelos para evitar fuga de información.

I-E. Paradigma de aprendizaje

Dado que el objetivo del problema consiste en estimar el valor numérico de *salary* a partir de un vector de características heterogéneas (catégoricas y numéricas) asociadas al puesto, la empresa y la oferta laboral, el paradigma de aprendizaje adecuado es el **aprendizaje supervisado de regresión**. Formalmente, se busca aproximar una función $f : \mathcal{X} \rightarrow \mathbb{R}$, donde $\mathcal{X}$ es el espacio de características codificadas y $\mathbb{R}$ el espacio de salarios en euros, minimizando una función de error $\mathcal{L}(y, \hat{y})$ del tipo error cuadrático medio o error absoluto medio sobre un conjunto de entrenamiento $\{(x_i, y_i)\}_{i=1}^N$.

La elección de regresión frente a clasificación se justifica por varias razones: (i) el salario es inherentemente continuo y discretizarlo en rangos implicaría pérdida de información y sensibilidad a la elección arbitraria de los intervalos; (ii) las métricas de regresión (RMSE, MAE, R^2 , MAPE) permiten

interpretar el error directamente en euros y compararlo con la dispersión salarial observada en el mercado; y (iii) los trabajos previos revisados en la Sección II demuestran resultados sólidos con regresores de tipo *ensemble* sobre datasets de características equivalentes [3], [4]. Como referencia se construirá un *baseline* lineal (*Ridge Regression*) y se compararán modelos no lineales (Random Forest, Gradient Boosting y XGBoost) bajo una estrategia de *k-fold cross-validation* con $k = 5$ y partición estratificada por *job_title* —variable de baja cardinalidad con cuatro categorías y una proporción de valores nulos inferior al 1 %— para garantizar representatividad de todos los perfiles laborales en cada pliegue.

II. ESTADO DEL ARTE

El problema de predecir salarios usando ML ha sido abordado de forma recurrente durante los últimos años, con especial énfasis en el sector de Tecnologías de la Información y la Ciencia de Datos. A continuación se resumen cuatro trabajos relevantes que emplean **paradigmas de regresión supervisada** sobre datasets similares al aquí analizado.

Matbouli y Alghamdi [1] publicaron en la revista *Information* (MDPI, 2022) un estudio que presenta modelos estadísticos de ML para predicción salarial basados en características ocupacionales y organizacionales del mercado laboral saudí. Utilizan un **paradigma supervisado de regresión** comparando regresión lineal múltiple (MLR) con procesos Gaussianos bayesianos (*Bayesian Gaussian Process Regression*, BGPR) y redes neuronales artificiales. La metodología de validación emplea separación aleatoria con *k-fold cross-validation*. Las métricas son R^2 y el error cuadrático medio

$RMSE = \sqrt{\frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2}$. Los autores reportan que la BGPR redujo el RMSE hasta en un 80 % frente a la MLR y mejoró sustancialmente el R^2 , demostrando la ventaja de los modelos no paramétricos en esta tarea.

Wang [2] publicó en *Wireless Communications and Mobile Computing* (Wiley, 2022) un estudio sobre la predicción del salario inicial de recién egresados. El **paradigma es de regresión supervisada** con una variante de clasificación para agrupar rangos salariales. Emplea **regresión lineal múltiple, Random Forest y XGBoost** con análisis de importancia de variables. La validación se realiza mediante *5-fold cross-validation* y las métricas son R^2 ajustado, MAE y MAPE, definido como $MAPE = \frac{100\%}{N} \sum_{i=1}^N \left| \frac{y_i - \hat{y}_i}{y_i} \right|$. Los resultados indican que la experiencia, el tamaño de la empresa y la ubicación concentran el 87 % de la importancia predictiva y XGBoost obtiene el menor MAPE. Aunque el contexto difiere del mercado profesional de Ciencia de Datos, estos factores son consistentes con los hallazgos del sector y orientan la selección de variables del presente estudio.

Jiang [3] publicó en *Applied and Computational Engineering* (2024) el estudio “*The investigation and prediction for salary trends in the data science industry*”, directamente relacionado con el problema aquí planteado. El autor adopta un **paradigma de regresión supervisada** comparando cuatro modelos: **Random Forest, XGBoost, redes neuronales artificiales (MLP) y Support Vector Regression (SVR)**, entrenados sobre datos salariales del sector de Ciencia de Datos de los últimos tres años. La validación se realiza mediante *cross-validation* y las métricas son RMSE y R^2 . Los resultados indican que las redes neuronales y SVR obtienen el menor RMSE, mientras que XGBoost es el más veloz; en todos los modelos, la experiencia y la ubicación geográfica resultan los predictores de mayor peso, hallazgo directamente extrapolable a las variables `seniority_level` y `headquarter` de nuestro dataset.

Martín *et al.* [4] en el *International Journal of Computational Intelligence Systems* (Atlantis/Springer, 2018) abordaron “*Salary Prediction in the IT Job Market with Few High-Dimensional Samples*” en el mercado español. El enfoque es de **regresión supervisada** con énfasis en escenarios de pocas muestras y alta dimensionalidad, situación análoga a nuestro dataset de 944 registros. Comparan regresiones regularizadas (Lasso, Ridge, Elastic-Net), *Support Vector Regression* (SVR) y Random Forest, validando mediante *leave-one-out cross-validation* (LOOCV). Las métricas incluyen RMSE, MAE y el coeficiente de correlación de Pearson $r = \frac{\sum (y_i - \bar{y})(\hat{y}_i - \bar{\hat{y}})}{\sqrt{\sum (y_i - \bar{y})^2 \cdot \sum (\hat{y}_i - \bar{\hat{y}})^2}}$, que mide la correlación lineal entre valores reales y predichos. Los autores concluyen que Lasso y SVR ofrecen el mejor compromiso entre interpretabilidad y error, con la experiencia y el tipo de contrato como factores más correlacionados con el salario.

En conjunto, los cuatro trabajos emplean **regresión supervisada** como paradigma, coinciden en el uso de *ensembles* basados en árboles como modelos de mayor desempeño, y reportan métricas R^2 , RMSE, MAE y MAPE para evaluar la predicción continua del salario. Adicionalmente, convergen en señalar el nivel de experiencia, la ubicación geográfica y el

título del puesto como determinantes salariales de mayor peso, hallazgo que guía la selección de modelos y la estrategia de preprocesamiento propuesta en la Sección I, cuyos equivalentes en el dataset son `seniority_level`, `headquarter` y `job_title`.

REFERENCIAS

- [1] Y. T. Matbouli y S. M. Alghamdi, “Statistical Machine Learning Regression Models for Salary Prediction Featuring Economy-Wide Activities and Occupations,” *Information*, vol. 13, no. 10, art. 495, 2022. DOI: <https://doi.org/10.3390/info13100495>
- [2] Y. Wang, “Prediction of Factors Influencing the Starting Salary of College Graduates Based on Machine Learning,” *Wireless Communications and Mobile Computing*, vol. 2022, art. 7845545, pp. 1–11, 2022. DOI: <https://doi.org/10.1155/2022/7845545>
- [3] W. Jiang, “The Investigation and Prediction for Salary Trends in the Data Science Industry,” *Applied and Computational Engineering*, vol. 50, pp. 8–14, 2024. DOI: <https://doi.org/10.54254/2755-2721/50/20241102>
- [4] I. Martín, A. Mariello, R. Battiti y J. A. Hernández, “Salary Prediction in the IT Job Market with Few High-Dimensional Samples: A Spanish Case Study,” *International Journal of Computational Intelligence Systems*, vol. 11, no. 1, pp. 1192–1209, 2018. DOI: <https://doi.org/10.2991/ijcis.11.1.90>